

Projecte Proxmox avançat

Integració i Optimització

Configuració Avançada

Configuració de Clústers

La configuració d'un clúster a Proxmox consisteix a agrupar diversos servidors físics o hipervisors independents, anomenats nodes, perquè treballin de manera conjunta i coordinada com si fossin un únic sistema unificat. A la nostra infraestructura, hem unit els tres nodes configurats prèviament per crear aquest entorn col·laboratiu. Aquesta arquitectura permet que tots els servidors comparteixin els seus recursos computacionals, les configuracions de xarxa i els repositoris d'emmagatzematge de manera eficient, creant una base sòlida per a entorns empresarials exigents.

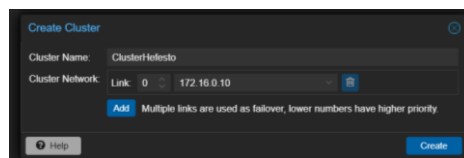
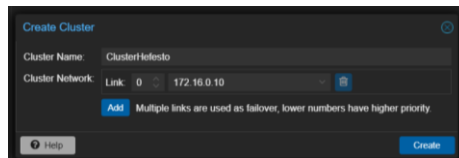
El principal avantatge d'aquesta configuració a nivell de gestió global és la centralització absoluta de l'administració. En formar un clúster, s'elimina la necessitat d'iniciar sessió a la interfície de cada servidor per separat. Des d'un únic panell de control web, l'administrador pot monitoritzar el rendiment general, desplegar noves màquines virtuals, aplicar polítiques de seguretat i gestionar l'emmagatzematge de tots els nodes simultàniament, fet que redueix dràsticament la complexitat i el temps dedicat a les tasques operatives diàries.

Pel que fa a la millora de la disponibilitat, el clúster és el requisit fonamental per implementar l'Alta Disponibilitat (HA). Si un dels nodes experimenta una fallada crítica, com una caiguda d'energia o una avaria de hardware, el clúster, en mantenir el quòrum, detecta la caiguda de manera automàtica i reinicia immediatament les màquines virtuals afectades als nodes que segueixen operatius, garantint la continuïtat del servei. A més, aquesta configuració permet realitzar migracions en calent, movent servidors virtuals d'un node a un altre sense interrompre el seu funcionament per dur a terme manteniments preventius a la infraestructura física.

Configuració del clúster pas per pas

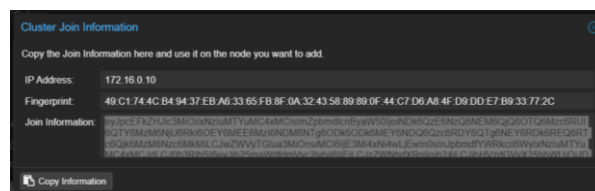
Crear el clúster al primer node

Em situo al node `proxmox` i, des de la secció **Datacenter** → **Cluster**, faig clic a **Create Cluster**. Defineixo el nom “ClusterHefesto” i la xarxa de comunicació interna (172.16.0.10/24). Aquesta xarxa la fa servir Corosync per intercanviar latits de cor entre nodes; per això és important que sigui estable i de baixa latència.



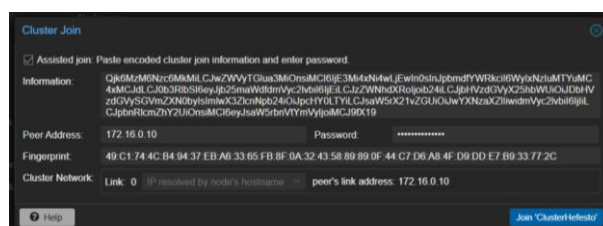
Copiar la informació de Join


Un cop creat el clúster, accedeixo a **Join Information** i copio la cadena codificada que conté l’empremta digital del node mestre. Aquesta dada és la que faré servir des dels altres nodes per unir-s’hi de manera segura.



Unir proxmox2 al clúster

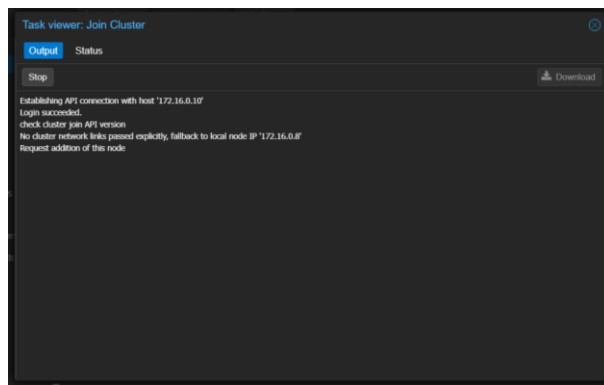
Al segon node accedeixo a **Datacenter** → **Cluster** → **Join Cluster**, enganxo la informació copiada, indico la IP del node mestre i la contrasenya de root. Després d’uns segons, el node queda integrat i visible des de qualsevol dels altres.






Unir proxmox3 al clúster

Repeteix exactament el mateix procediment al tercer node. Un cop finalitza, els tres nodes apareixen llistats sota el `ClusterHefesto` amb el seu `Quorum: Yes`, indicant que el clúster està plenament operatiu.




Servidor de backups

S'ha instal·lat un proxmox addicional als que ja teníem (instal·lació dels nodes explicada al projecte "Proxmox", he afegit dues targetes de xarxa una connectada a LAN i una altra a la xarxa amb la que proxmox es comunica amb el NAS (172.17...), aprofitem aquesta xarxa ja que la vam crear expressament per no saturar la LAN principal, la LAN (172.16...) la deixarem per administració:



Resultat final de configuració, un cop revisat, procedim amb la instal·lació



Ara li creo un DNS a pfSense per accedir còmodament a la administració:

Host Overrides				
Host	Parent domain of host	IP to return for host	Description	Actions
bot	hefesto.digital	172.16.0.3	Hefesto AI	 
pbs	hefesto.digital	172.16.0.7	Backup Server Proxmox	 
pfsense	hefesto.digital	172.16.0.1	pfsense	 
proxmox	hefesto.digital	172.16.0.4	Cluster Proxmox (IP flotante)	 
truenas	hefesto.digital	172.16.0.9	TrueNAS	 
web	hefesto.digital	10.0.0.10	Web DMZ	 
zabbix	hefesto.digital	172.16.0.5	Zabbix Server	 

Enter any individual hosts for which the resolver's standard DNS lookup process should be overridden and a specific IPv4 or IPv6 address should automatically be returned by the

Accedeixo a aquest nou server i li dono IP a la segona targeta de xarxa que es per on comunicarà amb el clúster:

```

No es seguro | https://pbs.hefesto.digital:8007/#pbsXtermJsConsole
PROXMOX Backup Server 4.1.0
GNU nano 8.4 /etc/network/interfaces
auto lo
iface lo inet loopback

auto nic0
iface nic0 inet static
    address 172.16.0.7/24
    gateway 172.16.0.1

auto nic1
iface nic1 inet static
    address 172.17.0.6/24

source /etc/network/interfaces.d/*

root@pbs:~# systemctl restart networking.service
root@pbs:~# ip a
1: lo: <LOOPBACK,UP,LOWER_UP> mtu 65536 qdisc noqueue state UNKNOWN group default qlen 1000
    link/loopback 00:00:00:00:00:00 brd 00:00:00:00:00:00
    inet 127.0.0.1/8 scope host lo
        valid_lft forever preferred_lft forever
    inet6 ::1/128 scope host noprefixroute
        valid_lft forever preferred_lft forever
2: nic0: <BROADCAST,MULTICAST,UP,LOWER_UP> mtu 1500 qdisc fq_codel state UP group default qlen 1000
    link/ether 08:00:27:d2:5b:8e brd ff:ff:ff:ff:ff:ff
    altname enx080027d25b8e
    inet 172.16.0.7/24 scope global nic0
        valid_lft forever preferred_lft forever
    inet6 fe80::a00:27ff:fed2:5b8e/64 scope link tentative proto kernel_ll
        valid_lft forever preferred_lft forever
3: nic1: <BROADCAST,MULTICAST,UP,LOWER_UP> mtu 1500 qdisc fq_codel state UP group default qlen 1000
    link/ether 08:00:27:97:e2:16 brd ff:ff:ff:ff:ff:ff
    altname enx08002797e216
    inet 172.17.0.6/24 scope global nic1
        valid_lft forever preferred_lft forever
    inet6 fe80::a00:27ff:fe97:e216/64 scope link proto kernel_ll
        valid_lft forever preferred_lft forever

```

Creo un datastore al pbs, de moment com que no tenim cap USB connectat el provarem en el disc Local del propi backup-server:

Add: Datastore

General

Prune Options

Name:

hefesto-backups

GC Schedule:

daily

Datastore Type:

Local

Prune Schedule:

daily

Backing Path:

/mnt/datastore/hefesto-back

Device:

Device path

S3 Endpoint ID:

Bucket:

Comment:

Help

Advanced

Add

Amb la comanda “proxmox-backup-manager cert info” obtinc el “fingerprint sha256” que ens farà falta més endavant:

← → ↻ No es seguro https://pbs.hefesto.digital:8007/#pbsXtermJsConsole

PROXMOX Backup Server 4.1.0

Documentation Tasks 1 root@pam

Dashboard

Notes

Configuration

Access Control

Remotes

S3 Endpoints

Traffic Control

Certificates

Notifications

Subscription

Administration

Shell

Storage / Disks

Linux pbs 6.17.2-1-pve #1 SMP PREEMPT_DYNAMIC PMX 6.17.2-1 (2025-10-21T11:55Z) x86_64

The programs included with the Debian GNU/Linux system are free software; the exact distribution terms for each program are described in the individual files in /usr/share/doc/*/copyright.

Debian GNU/Linux comes with ABSOLUTELY NO WARRANTY, to the extent permitted by applicable law.

root@pbs:~# proxmox-backup-manager cert info

Subject: O = Proxmox Backup Server, OU = 64A92C3D-E0A2-4E26-8246-65E7B410D578, CN = pbs.hefesto.digital

IP:[127, 0, 0, 1]

IP:[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1]

DNS:localhost

DNS:pbs

DNS:pbs.hefesto.digital

Issuer: O = Proxmox Backup Server, OU = 64A92C3D-E0A2-4E26-8246-65E7B410D578, CN = pbs.hefesto.digital

Validity:

Not Before: Apr 28 15:55:08 2026 GMT

Not After : Aug 29 15:55:08 3025 GMT


Fingerprint (sha256): d2:0d:2b:5a:5f:8b:b7:7c:af:2e:17:f4:fc:56:c8:a0:29:b5:46:60:62:a6:66:fa:c3:5c:42:57:f5:12:83:45

Public key type: rsaEncryption


Public key bits: 4096

root@pbs:~#

Creo un usuari i li dono permisos per administrar aquests backups:




Ara ja podem anar al clúster de proxmox i afegir aquest servidor:




Amb això ja queda afegit el servidor de backups al nostre clúster de proxmox, en el següent punt mirarem de provar i analitzar el sistema i intentarem automatitzar-lo.


Indico el mode que serà “snapshot” per guardar la instantània de la maquina en aquell moment i on i quan volem guardar, en el nostre cas em decidit a les 21:00 de cada dia i òbviament en el storage creat al server pbs:



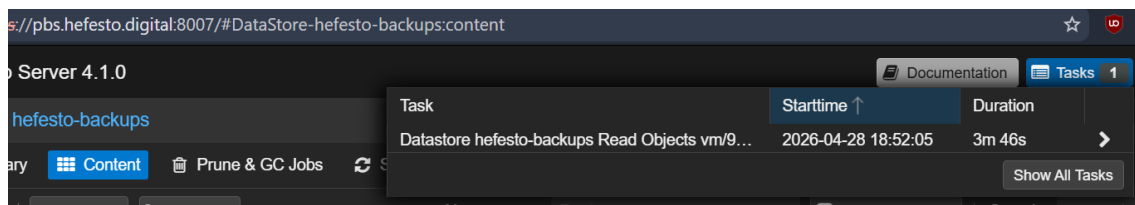
He forçat el backup per que el realitzi ara mateix i podem veure com el server pbs rep els backups correctament:



Ara mirarem de restaurar aquest backup:



Podem veure que al servidor de backups ens mostra una notificació amb la tasca en curs:



Resultat de la maquina virtual ja restaurada:

No es seguro | <https://proxmox.hefesto.digital:8006/#v1:0:=storage%2Fproxmox%2Fpbs-hefesto>


PROXMOX Virtual Environment 9.1.7

Task viewer: VM 102 - Restore

Output Status

```
progress 79% (read 3393191300 bytes, zeroes = 70% (2390621300 bytes), duration 609 sec)
progress 80% (read 34359738368 bytes, zeroes = 76% (26336034816 bytes), duration 609 sec)
progress 81% (read 34791751680 bytes, zeroes = 76% (26768048128 bytes), duration 609 sec)
progress 82% (read 35219570688 bytes, zeroes = 77% (27195867136 bytes), duration 609 sec)
progress 83% (read 35651584000 bytes, zeroes = 77% (27627880448 bytes), duration 609 sec)
progress 84% (read 36079403008 bytes, zeroes = 77% (28055699456 bytes), duration 609 sec)
progress 85% (read 36507222016 bytes, zeroes = 78% (28483518464 bytes), duration 609 sec)
progress 86% (read 36939235328 bytes, zeroes = 78% (28915531776 bytes), duration 609 sec)
progress 87% (read 37367054336 bytes, zeroes = 78% (29343350784 bytes), duration 609 sec)
progress 88% (read 37799067648 bytes, zeroes = 78% (29775364096 bytes), duration 609 sec)
progress 89% (read 38226886656 bytes, zeroes = 79% (30203183104 bytes), duration 609 sec)
progress 90% (read 38654705664 bytes, zeroes = 79% (30631002112 bytes), duration 609 sec)
progress 91% (read 39086718976 bytes, zeroes = 79% (31063015424 bytes), duration 609 sec)
progress 92% (read 39514537984 bytes, zeroes = 79% (31490834432 bytes), duration 609 sec)
progress 93% (read 39946551296 bytes, zeroes = 79% (31922847744 bytes), duration 609 sec)
progress 94% (read 40374370304 bytes, zeroes = 80% (32350666752 bytes), duration 609 sec)
progress 95% (read 40802189312 bytes, zeroes = 80% (32778485760 bytes), duration 609 sec)
progress 96% (read 41234202624 bytes, zeroes = 80% (33210499072 bytes), duration 609 sec)
progress 97% (read 41662021632 bytes, zeroes = 80% (33638318080 bytes), duration 609 sec)
progress 98% (read 42094034944 bytes, zeroes = 80% (34070331392 bytes), duration 609 sec)
progress 99% (read 42521853952 bytes, zeroes = 81% (34498150400 bytes), duration 609 sec)
progress 100% (read 42949672960 bytes, zeroes = 81% (34858860544 bytes), duration 610 sec)
restore image complete (bytes=42949672960, duration=610.58s, speed=67.08MB/s)
rescan volumes...
TASK OK
```

Com es pot veure a continuació ens ha creat una nova màquina restaurada que porta exactament el contingut de la original de la qual s'ha extret el backup, com era el primer cop em decidí fer que el restore generi una còpia a un altre node de proxmox però es podria fer que la planxi a sobre perfectament:



Alta Disponibilitat (HA)

L'Alta Disponibilitat (HA) és una arquitectura dissenyada per garantir la continuïtat del servei de les màquines virtuals davant de qualsevol caiguda de hardware. Perquè aquesta estratègia funcioni correctament, ha estat fonamental implementar Ceph com a sistema d'emmagatzematge distribuït. Ceph unifica els discos físics de tots els nodes creant un clúster d'emmagatzematge compartit, redundat i altament escalable. Això assegura que els discos virtuals de les màquines no resideixin de manera local en un sol servidor físic, sinó que estiguin replicats i accessibles des de tota la infraestructura. Si un node pateix una avaria crítica, les seves dades segueixen intactes i completament disponibles a través de la xarxa, eliminant el risc de pèrdua d'informació i trencant la dependència de l'emmagatzematge local.

Sobre aquesta base sòlida d'emmagatzematge compartit, he configurat el gestor d'Alta Disponibilitat natiu de Proxmox. Aquest servei monitoritza constantment l'estat de la infraestructura i, davant la caiguda sobtada d'un node, aplica una estratègia de resposta ràpida basada en la redirecció automàtica. El clúster aïlla el servidor caigut per evitar la corrupció de dades i, de manera autònoma, ordena l'arrencada de les màquines virtuals afectades als nodes supervivents. La importància d'aquesta redirecció automàtica rau en el fet que el sistema es recupera de l'incident en qüestió de segons sense

requerir la intervenció manual de l'administrador, garantint així que els serveis crítics tornin a estar operatius gairebé immediatament.

Ceph vs NAS amb HA


L'exemple basat en Ceph amb discos locals representa una arquitectura d'emmagatzematge definit per programari (SDS) totalment distribuïda. En aquesta configuració, Proxmox utilitza els discos físics addicionals que hem instal·lat a cada node per crear un magatzem de dades únic i compartit entre tota la xarxa. La principal característica tècnica és que Ceph no depèn d'un servidor extern, sinó que replica les dades de les màquines virtuals de manera redundant entre els propis nodes del clúster. Això garanteix que, si un node falla físicament, els altres dos nodes ja contenen còpies exactes de les dades, permetent que el sistema d'Alta Disponibilitat reiniciï els serveis immediatament sense pèrdua d'informació i aprofitant el hardware intern de manera eficient.

Per contra, l'exemple del NAS amb Alta Disponibilitat utilitza un model d'emmagatzematge centralitzat. En aquest cas, els discos virtuals no es troben dins dels nodes, sinó en un dispositiu extern connectat a través de la xarxa dedicada que hem configurat prèviament. L'avantatge d'aquest mètode és la simplicitat de gestió, ja que tots els nodes del clúster veuen el mateix punt d'emmagatzematge de manera simultània mitjançant protocols com NFS o iSCSI. Quan el gestor d'HA detecta la caiguda d'un node, simplement ordena a un altre servidor operatiu que munti el disc virtual des del NAS i arrenqui la màquina. A diferència de Ceph, aquí la redundància depèn de la robustesa del propi NAS, facilitant una recuperació ràpida ja que no és necessari sincronitzar dades entre nodes durant el procés de commutació per fallada.

Configuració d'HA pas per pas


Verificar la migració segura

A **Datacenter** → **Options** confirmo que la migració utilitza la xarxa interna (`network=172.17.0.3/24, type=secure`) i que la política de shutdown és `migrate`, perquè a l'apagar un node ordenadament les VMs es desplacin automàticament.




Afegir VMs al gestor d'HA.

Des de **Datacenter** → **HA** → **Resources** afegeixo les VMs crítiques (Test-Replica, Zabbix, etc.) indicant `Max. Restart = 1`, `Max. Relocate = 2` i `Failback = true`. Amb aquests paràmetres, davant d'un fallada, el gestor intentarà reiniciar la VM una vegada al mateix node i, si no és possible, la mourà a un altre.



Verificar l'estat del gestor.


A **HA** → **Status** comprovo que un dels nodes apareix com a `master (active)` i la resta com a `lrm (active)` o `idle`. Aquest és l'indicador que els watchdogs estan operatius i que la HA està plenament en marxa.



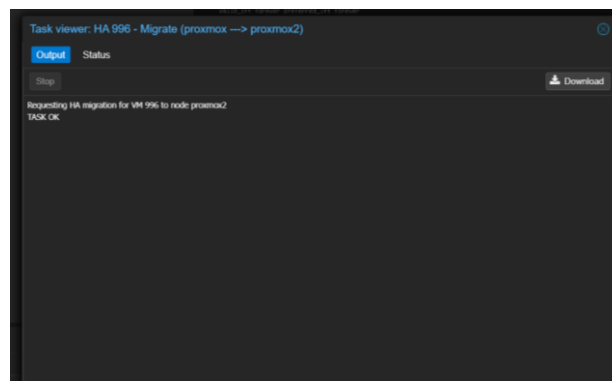
Prova de migració en viu.



Per validar la configuració, faig una migració en viu de la VM 996 (THASARIAN) des de `proxmox` cap a `proxmox2` mitjançant **Migrate** → **Online**. Proxmox transfereix els blocs de memòria diferencialment fins que la VM queda activa al node destí sense pèrdua de servei.

Diàleg Migrate VM amb Mode Online

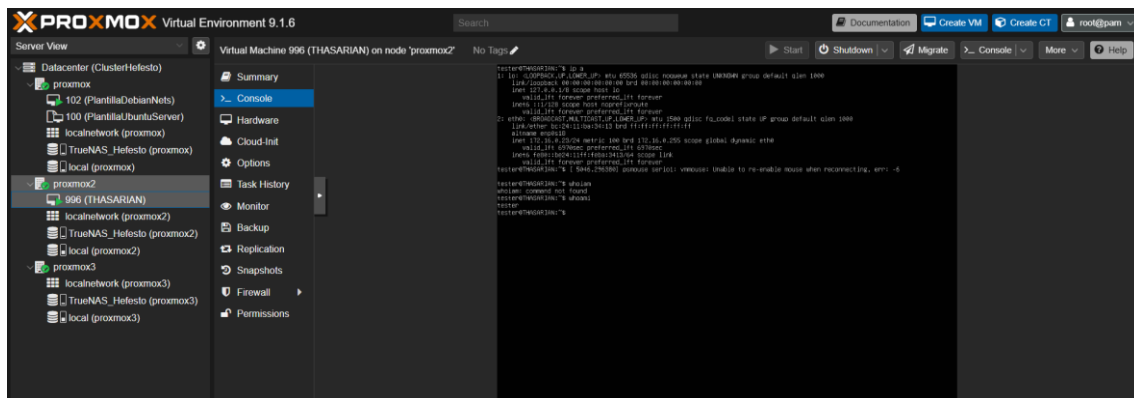


Task viewer amb el progrés de la migració (transferred/speed)





VM en execució al node destí 'proxmox2'



Ceph: Emmagatzematge Distribuït

Ceph és un sistema d'emmagatzematge distribuït de codi obert que converteix els discos físics dels nodes del clúster en un únic pool d'emmagatzematge unificat, replicat i tolerant a fallades. La seva integració nativa amb Proxmox el converteix en la base ideal per a entorns d'Alta Disponibilitat, ja que elimina la dependència de qualsevol disc local: les dades viuen distribuïdes per tota la infraestructura.

El funcionament es basa en tres components clau:

1. **OSD (Object Storage Daemon):** és el procés que s'executa per cada disc físic dedicat a Ceph. Cada OSD gestiona la lectura, escriptura i replicació de les dades al seu disc. A la nostra configuració hem creat un OSD per node (`/dev/sdb`), de manera que disposem de 3 OSDs en total que comparteixen la càrrega.
2. **Monitor (MON):** és el component responsable de mantenir el mapa de l'estat del clúster (qui està viu, qui està caigut, on viuen les dades). Per garantir el quòrum i evitar situacions de "split-brain" cal sempre un nombre senar de monitors. Per això hem desplegat un MON a cadascun dels 3 nodes.
3. **Manager (MGR):** ofereix mètriques, dashboards i tasques de gestió. Inicialment només es desplega un Manager, però per garantir l'alta disponibilitat de la gestió hem afegit Managers addicionals als nodes ``proxmox2`` i ``proxmox3``.

Sobre aquests components creem un **Pool**, que és la unitat lògica on Proxmox emmagatzema els discos virtuals. La política que hem definit és:


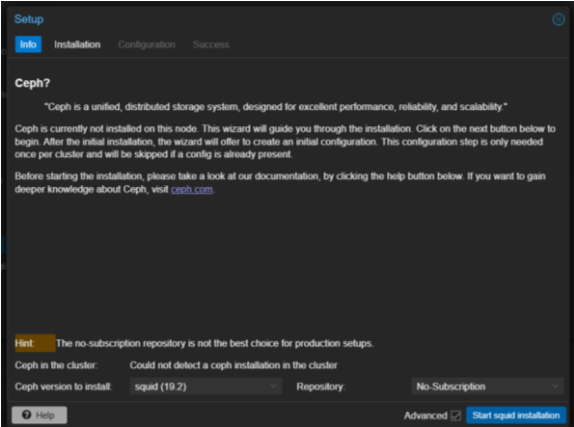

4. **Size = 3** cada bloc es replica tres vegades, una per cada node.
5. **Min Size = 2** el clúster continua funcionant mentre dos nodes estiguin operatius.
6. **PG (Placement Groups) = 128**, valor recomanat per a 3 OSDs.

Aquesta configuració ens permet perdre un node sencer sense pèrdua de dades ni interrupció del servei, complint amb els requisits d'Alta Disponibilitat exigits pel projecte.


Instal·lació de Ceph

Des de la pestanya **Ceph** del primer node faig clic a **Install Ceph** i selecciono la versió més estable disponible (Squid, 19.2). El procés desplega els paquets ``ceph-mgr``, ``ceph-osd``, ``ceph-mon`` i les seves dependències, i configura les xarxes pública i de clúster (totes dues sobre 172.16.0.0/24 al nostre cas, ja que disposem d'una sola interfície dedicada). Repeteixo el procés a ``proxmox2`` i ``proxmox3``.


Selecció de versió Ceph squid (19.2)



Configuració de Public/Cluster Network




Installation successful





Creació d'OSDs


Per a cada node, des de **Ceph** → **OSD** afegeixo el disc `/dev/sdb` com a nou OSD. Proxmox formata el disc amb BlueStore, l'emmagatzematge nadiu de Ceph, i el registra al CRUSH map. Un cop he creat els tres OSDs, la vista global mostra `3/3 up & in` i el pes de cada OSD repartit uniformement.

Create Ceph OSD a proxmox amb `/dev/sdb`







Llista d'OSDs als 3 nodes osd.0, osd.1, osd.2 — up/in




Creació del Pool Ceph

A **Ceph** → **Pools** → **Create** creo el pool `HefestoPool1` amb Size = 3, Min Size = 2 i 128 PGs. Marco l'opció **Add as Storage** perquè Proxmox el registri automàticament com a destinació RBD a tot el clúster, accessible des de qualsevol node.

Diàleg Create Ceph Pool amb els paràmetres



Storage HefestoPool1 visible als 3 nodes




Configuració de Monitors i Managers

Per defecte Proxmox crea només un Manager (`mgr.proxmox`) al node on s'inicialitza Ceph. Si aquest node cau, perdem temporalment l'accés a les mètriques i a part de les funcions de gestió de Ceph, encara que el clúster d'emmagatzematge continuï servint dades.

Per evitar-ho, des de la pestanya **Ceph** → **Monitor**, secció **Manager**, afegixo Managers addicionals als altres dos nodes mitjançant el botó **Create**. Un cop creats, només un Manager està en estat **active** i la resta queden en

standby. Si el Manager actiu cau, un dels en standby pren el relleu de manera automàtica.


Ceph → Monitor mostrant els 3 Monitors i els 3 Managers



Name	Host	Status	Address	Version
mgr.proxmox	proxmox	active	172.16.0.10	19.2.3
mgr.proxmox2	proxmox2	standby	172.16.0.8	19.2.3
mgr.proxmox3	proxmox3	standby	172.16.0.6	19.2.3

Pel que fa als Monitors, ja he creat un MON a cadascun dels tres nodes durant la fase d'instal·lació. Tots tres apareixen amb estat `running` i adreces 172.16.0.10, 172.16.0.8 i 172.16.0.6, formant el quòrum de Monitors necessari per a l'operació de Ceph. Amb Monitors i Managers redundants, tota la pila Ceph queda completament tolerant a fallades.

Declaro el pool Ceph com un storage RBD al Datacenter perquè Proxmox sàpiga que pot col·locar-hi discos virtuals i contenidors:




Add: RBD

General | Backup Retention

ID: hefesto_ceph | Nodes: All (No restrictions) | Pool: HefestoPool1 | Enable: ☒ | Monitor(s): proxmox,proxmox2,proxmox3 | Content: Disk image, Container | User name: admin | KRBD: ☐

☒ Use Proxmox VE managed hyper-converged ceph pool

Definir la política de tolerància a fallades d'aquesta VM:



Edit: Resource: Container/Virtual Machine

VM: 990 | Failback: ☒ | Max. Restart: 1 | Request State: started | Max. Relocate: 2 | Comment:

Max. Restart = 1: si la VM cau, el gestor d'HA intentarà reiniciar-la una sola vegada al mateix node abans de moure-la.

Max. Relocate = 2: si el reinici local falla, el gestor podrà reubicar la VM fins a dues vegades en altres nodes del clúster intentant arrencar-la.

Característiques de Rèplica


A més de l'Alta Disponibilitat amb Ceph, Proxmox ofereix un mecanisme alternatiu de redundància anomenat **replicació**. A diferència de Ceph (que escriu sincrònicament a tots els nodes), la replicació amb ZFS treballa de manera asíncrona enviant snapshots incrementals a un node destí cada cert temps. Això la fa més lleugera en consum d'ample de banda però no garanteix RPO=0: en cas de caiguda, podem perdre els canvis succeïts entre l'últim snapshot replicat i la fallada.



Replicació amb ZFS

Afegir un disc dedicat a cada node

A cada un dels tres nodes, des del menú de Disks afegeixo un nou disc físic (`/dev/sdc`) que dedicaré exclusivament a ZFS. Mantinc Ceph i ZFS en discos separats per evitar contencions d'I/O.

Llista de Disks amb /dev/sdc disponible als 3 nodes






Crear el pool ZFS

Des de **Disks** → **ZFS** → **Create: ZFS** creo un pool anomenat `ZFS-Replication`, RAID Level **Single Disk**, compressió *`on`* i *ashift `12`*. Repeteixo el procés als altres dos nodes mantenint exactament el mateix nom de pool, requisit indispensable perquè la replicació funcioni.

Create ZFS amb el nom ZFS-Replication



Create: ZFS


Name: RAID Level:

Add Storage: ☐ Compression:

ashift:

☒	Device ↑	Model	Serial	Size	Order
☒	/dev/sdc	VBOX_HARDDISK	VB889bef25-f07aebc6	32.21 GB	

Note: ZFS is not compatible with disks backed by a hardware RAID controller. For details see [the reference documentation](#).



Pool ZFS-Replication ONLINE als 3 nodes

Node 'proxmox'

Reboot Shutdown Shell Bulk Actions Help

Reload Create: ZFS Detail


No pool selected More

Name ↓	Size	Free	Allocated	Fragmenta...	Health
ZFS-Replication	31.68 GB	31.67 GB	503.81 KB	0%	ONLINE


Left sidebar: Updates, Repositories, Firewall, Disks, LVM, LVM-Thin, Directory, ZFS, Ceph, Replication, Task History, Subscription

Repetim el procés en els altres nodes:

Proxmox2



Proxmox3




Declarar el pool com a storage al Datacenter

Un cop disposo del pool ZFS local a cadascun dels tres nodes, el següent pas és declarar-lo a Proxmox com un emmagatzematge accessible des del Datacenter. Aquesta declaració és necessària perquè la funcionalitat de replicació de Proxmox només pot operar sobre emmagatzematges de tipus ZFS local, ja que es basa en l'enviament incremental de snapshots nadius de ZFS (`zfs send | zfs recv`).

Procedeixo des de **Datacenter** → **Storage** → **Add** → **ZFS** i indico:

7. **ID:** `ZFS-Pool1` (nom amb què apareixerà a la interfície).
8. **ZFS Pool:** `ZFS-Replication` (pool físic creat al pas anterior).
9. **Content:** `\*Disk image, Container\*` (només discos virtuals; els ISOs i backups es queden al NAS).
10. **Thin provision:** desactivat per garantir reserva d'espai.
11. **Nodes:** `\*All (no restrictions)\*`, perquè el pool existeix amb el mateix nom als tres nodes i, per tant, la replicació funcionarà entre qualssevol d'ells.

Add ZFS — formulari amb ID i ZFS Pool



Add: ZFS

General Backup Retention

ID: ZFS-Pool1 Nodes: All (No restrictions)


ZFS Pool: ZFS-Replication Enable: ☒

Content: Disk image, Container Thin provision: ☐

Block Size: 16k

[Help](#) [Add](#)

Llista de Storage al Datacenter amb ZFS-Pool1 als 3 nodes




A diferència del NFS o de Ceph, **ZFS-Replication NO és emmagatzematge compartit**: cada node té la seva pròpia còpia local i Proxmox sincronitza els blocs canviats periòdicament. Per això, la replicació ZFS és una alternativa més lleugera a Ceph quan no es disposa de prou discos o ample de banda per mantenir un clúster Ceph saludable.

Configuració del job de replicació

Crear una VM al pool ZFS


Creo la VM 992 (`ZFSReplicacion`) ubicant el seu disc al storage `ZFS-Pool1`. Aquesta serà la VM que replicarem.

Create VM amb Storage ZFS-Pool1




The screenshot shows the 'Create: Virtual Machine' dialog with the 'General' tab selected. The fields are as follows:

Field	Value
Node:	proxmox
VM ID:	994
Name:	ZFS-Replica
Add to HA:	☐
Resource Pool:	



The screenshot shows the 'Create: Virtual Machine' dialog with the 'OS' tab selected. The fields are as follows:

Field	Value
Use CD/DVD disc image file (iso)	☒
Storage:	TrueNAS_Hefesto
ISO image:	debian-12.13.0-amd64
Guest OS:	Linux
Type:	Linux
Version:	6.x - 2.6 Kernel
Use physical CD/DVD Drive	☐
Do not use any media	☐




The screenshot shows the 'Create: Virtual Machine' dialog with the 'Disks' tab selected. The fields are as follows:

Field	Value
scsi0	
Bus/Device:	SCSI 0
SCSI Controller:	VirtIO SCSI single
Storage:	ZFS-Pool1
Disk size (GiB):	10
Format:	Raw disk image (raw)
Cache:	Default (No cache)
Discard:	☐
IO thread:	☒

Definir el job de replicació

Sobre la VM, a la pestanya **Replication** → **Add**, configuro un job amb destí `proxmox3`, schedule `\*/2` (cada 2 minuts) i un comentari descriptiu. Aquest schedule el faig servir només per a la prova; en producció seria més raonable un valor de 15 o 30 minuts segons la criticitat de les dades.

Diàleg Create Replication Job



Validar el primer enviament

El primer cicle envia el snapshot complet (uns 186 MB al meu cas) i els següents són només incrementals. Al log es pot veure clarament la seqüència: `freeze guest filesystem → create snapshot → send/rcv → thaw filesystem`. La congelació del filesystem amb el QEMU Guest Agent garanteix que el snapshot sigui consistent.

Replication Log amb el detall de l'enviament

```
Replication Log
2026-04-14 23:18:06 992-0: start replication job
2026-04-14 23:18:06 992-0: guest => VM 992, running => 96714
2026-04-14 23:18:06 992-0: volumes => ZFS-Pool1:vm-992-disk-0
2026-04-14 23:18:07 992-0: freeze guest filesystem
2026-04-14 23:18:07 992-0: create snapshot '__replicate_992-0_1776201486__' on ZFS-Pool1:vm-992-disk-0
2026-04-14 23:18:07 992-0: thaw guest filesystem
2026-04-14 23:18:07 992-0: using secure transmission, rate limit: none
2026-04-14 23:18:07 992-0: incremental sync 'ZFS-Pool1:vm-992-disk-0' ( __replicate_992-0_1776201365__ => __replicate_992-0_1776201486__ )
2026-04-14 23:18:07 992-0: send from @ __replicate_992-0_1776201365__ to ZFS-Replication/vm-992-disk-0@ __replicate_992-0_1776201486__ estimated size is
2026-04-14 23:18:07 992-0: total estimated size is 186M
2026-04-14 23:18:07 992-0: TIME SENT SNAPSHOT ZFS-Replication/vm-992-disk-0@ __replicate_992-0_1776201486__
2026-04-14 23:18:09 992-0: successfully imported 'ZFS-Pool1:vm-992-disk-0'
2026-04-14 23:18:09 992-0: delete previous replication snapshot '__replicate_992-0_1776201365__' on ZFS-Pool1:vm-992-disk-0
2026-04-14 23:18:10 992-0: (remote_finalize_local_job) delete stale replication snapshot '__replicate_992-0_1776201365__' on ZFS-Pool1:vm-992-disk-0
2026-04-14 23:18:10 992-0: end replication job
```

zfs list al node destí mostrant el dataset replicat

PROXMOX Virtual Environment 9.1.7

Server View Node 'proxmox3'

Linux proxmox3 6.17.13-2-pve #1 SMP PREEMPT_DYNAMIC PMX 6.17.13-2 (2026-03-13T08:06z) x86_64

The programs included with the Debian GNU/Linux system are free software; the exact distribution terms for each program are described in the individual files in /usr/share/doc/*/*copyright.

Debian GNU/Linux comes with ABSOLUTELY NO WARRANTY, to the extent permitted by applicable law.

Last login: Fri Apr 10 18:14:22 2026 from 172.16.0.10

root@proxmox3:~# zfs list

NAME	USED	AVAIL	REFER	MOUNTPOINT
ZFS-Replication	19.5G	9.04G	96K	/ZFS-Replication
ZFS-Replication/vm-992-disk-0	19.5G	24.3G	4.30G	-